

DESCRIZIONE - OBIETTIVI - STRUMENTI - PASSAGGI

DESCRIZIONE, OBIETTIVI E STRUMENTI UTILIZZATI

- **DESCRIZIONE DEL PROGETTO:** analisi sull'inquinamento atmosferico generato dalle emissioni di CO2 e sulle principali conseguenze associate: tasso di mortalità legato alla qualità dell'aria, aumento delle temperature, scioglimento dei ghiacciai con conseguente innalzamento dei livelli del mare, produzione e utilizzo delle energie rinnovabili;
- **OBIETTIVI:** evidenziare le correlazioni tra causa ed effetto (emissioni di CO2 e relative conseguenze), e mettere in luce l'urgenza di un maggior utilizzo delle energie rinnovabili;
- **PASSAGGI:** ideazione dell'analisi, ricerca dei dataset, EDA, ETL/ELT, modellazione e relazione delle tabelle, realizzazione del report;
- **STRUMENTI UTILIZZATI:** Power BI, Power Query e Python.

PASSAGGI: EDA, ETL/ELT E RELAZIONI

1. Ho caricato i file CSV ed Excel su Power BI e ho iniziato ad esplorarli in Power Query;
2. Dove necessario ho rinominato le tabelle, i campi ed ho alzato le prime righe rendendole come intestazione;
3. Mi sono reso conto di una cosa: durante il caricamento dei dati, Power Query importa le colonne numeriche come testo. Poiché nei dataset che ho raccolto il separatore decimale utilizzato è il punto anziché la virgola, Power Query interpreta questi valori in modo errato: convertendo automaticamente il tipo di dato da Testo a Numero intero, rimuove il punto e altera di conseguenza i dati.
Per evitare questo errore, ho eliminato il passaggio di conversione automatica del tipo di dato, ho individuato tutte le colonne contenenti valori decimali, ho sostituito il punto con la virgola e infine ho modificato il tipo da Testo a Numero decimale, in modo da preservare l'integrità dei valori.
4. Nei file, nei campi numerici erano presenti dei valori "(spazio vuoto)" e dei Null. Entrambi i tipi di valori rappresentano mancanza di dati, per quei paesi in quelle annate, quindi per una validazione e coerenza, gli spazi vuoti li ho sostituiti con i Null sempre in Power Query;
5. **LAVORAZIONE SUI FILE PER EMISSIONI DI CO2:**
 - a. In Power Query, confrontando le tabelle "Emissione CO2 pro capite" ed "Emissione CO2 per fonte" ho eliminato tutti i campi che non mi sarebbero serviti alle analisi.
 - b. Ho preso il file "Emissione CO2 pro capite" (che era il Dataset con la colonna degli stati più popolata) ed in Python ho rimosso i record duplicati e tutti i campi eccezion fatta per "Country", in modo da estrapolarci una lista dei paesi che ho salvato in formato csv e nominato "Country_list", questo per crearmi una tabella delle dimensioni da relazionare a tutte le restanti tabelle dei fatti con gli stati presenti all'interno;
 - c. Confrontandola con le tabelle dei file sulle Emissioni di CO2, in Power Query ho rinominato la prima colonna delle tabelle da "Entity" in "Country" per allinearle;
 - d. Ho preso il file "Emissione CO2 per fonte" ed in Python ho rimosso i primi 3 campi, cioè quello dei paesi, il codice e l'anno. Ho preso l'intestazione dei campi, li ho trasformati in un Data frame il cui titolo che ho dato alla colonna è stato "Tipi di emissioni", ed infine ho eliminato "Annual CO2 emissions from" lasciando come contenuto solamente il tipo di emissione. Tutto questo per estrapolarci una lista in formato csv dei tipi di emissione come tabella delle dimensioni da relazionare a quelle dei fatti;

6. LAVORAZIONE SUI FILE PER LE ENERGIE RINNOVABILI:

- a. Per il file "Utilizzo di energie rinnovabili pro capite" ho preso il campo "Renewables (% equivalent primary energy)" i cui valori, invece che in formato percentuale, erano mostrati in formato testo, così in Power Query ho convertito la colonna in formato decimale, ne ho creata una personalizzata, prendendo la colonna di interesse dividendola per 100 e infine gli ho cambiato formato in %, eliminato quella errata e rinominato quella appena creata allo stesso modo, ottenendo dei dati corretti;
- b. Stesso procedimento eseguito anche per il campo "Renewables - % electricity" del file "Produzione energia da Rinnovabili".

7. LAVORAZIONE SUL FILE PER TASSO DI MORTALITA' ED INQUINAMENTO ATMOSFERICO:

- a. Ho rinominato i campi ed ho alzato la prima riga rendendola come intestazione, ho cambiato i formati di alcuni campi ed infine ho seguito la stessa procedura del punto 3, nient'altro di particolare.

8. LAVORAZIONE SUI FILE PER I GHIACCIAI:

- a. Successivamente ho preso i file "Estensione ghiacciaio Artico" ed "Estensione ghiacciaio Antartico" ed in Python ho rinominato i campi dell'estensione min. e max. rimuovendo i rispettivi nomi dei ghiacciai, dopodiché ho accodato le tabelle creando un nuovo file csv che ho nominato "Estensione ghiacciai", questo per avere un unico file con le estensioni per entrambi i ghiacciai e ridurre di 1 la quantità di tabelle;
- b. Ho preso il file "Estensione ghiacciai" e con Python ci ho ricavato una tabella con la loro lista che ho nominato "Lista ghiacciai" in csv, eliminando tutti i campi tranne i primi 2, sempre per crearmi una tabella delle dimensioni da relazionare a tutte le restanti tabelle dei fatti;
- c. Nei file sui ghiacciai, quello Artico presentava nomenclature differenti, così su Power Query ho deciso di unire i 2 nomi in un'unica soluzione per tutti i file e quindi maggiore chiarezza, cioè "Arctic Ocean/Greenland" e nei campi "CODE" ho sostituito i Null con "GRL" in quanto corrispondevano al ghiacciaio Artico;

9. LAVORAZIONE SUI FILE PER LE TEMPERATURE:

- a. Nel file "Aumento temperature Globali (per mese)" in Power Query il campo "Entity" l'ho rinominato "Month" in quanto contiene unicamente i 12 mesi dell'anno, e la colonna "Code" l'ho eliminata in quanto li è decontestualizzata;
 - b. Invece nel file "Temperature medie globali", nel campo "Code", essendo presente il codice per l'entità "world", ho deciso simbolicamente di dare dei codici anche al "Northern Hemisphere" ed al "Southern Hemisphere" rispettivamente "NH" e "SH" in quanto privi;
 - c. Infine nel file "Temperatura media per mesi" in Power Query ho invertito i campi con i record tramite l'"UnPivot", selezionando tutte le colonne dei valori per annualità, in modo da ridurre il quantitativo di colonne ricavandomi un campo per gli anni ed uno con le rispettive temperature medie.
10. La maggior parte dei campi relativi alle annualità riportava soltanto l'anno che ho convertito dal formato Testo al formato Intero. Tuttavia, in alcuni casi erano presenti delle date complete. In queste situazioni ho scelto di mantenere l'informazione completa, convertendo in Power Query tali campi dal formato Testo al formato Data e applicando, quando necessario, filtri basati sull'anno di interesse.
11. Le relazioni, una volta create le tabelle dei fatti, si sono create automaticamente, ma controllandole, sono risultate tutte corrette.